Systematische Analyse algorithmischer Hochfrequenzhandelsstrategien auf Polymarket: Architektur, Oracle-Latenzarbitrage und Infrastruktur-Optimierung

Die Landschaft der dezentralen Prognosemärkte (Decentralized Prediction Markets) hat sich in den vergangenen Jahren von einer Nische für Krypto-Enthusiasten zu einem hochkomplexen, institutionellen Handelsumfeld entwickelt. Polymarket, die derzeit weltweit dominierende Plattform in diesem Sektor, verarbeitet Milliardenvolumina und fungiert zunehmend als globaler, dezentraler Informationsaggregator für politische, ökonomische und gesellschaftliche Ereignisse.[1] Die Migration von einfachen Automated Market Maker (AMM) Systemen hin zu einem performanten Central Limit Order Book (CLOB) auf der Polygon-PoS-Blockchain hat die Tür für eine neue Klasse von Marktteilnehmern geöffnet: Algorithmische Hochfrequenzhändler (High-Frequency Trading, HFT).[3]

In diesem hochkompetitiven, durch technologische Asymmetrien geprägten Ökosystem generieren spezialisierte Akteure durch den Einsatz überlegener Infrastruktur, optimierter Softwarearchitekturen und tiefer Kenntnisse der Marktmikrostruktur signifikante und deterministische Profite. Ein herausragendes Beispiel für diese neue Generation von Marktteilnehmern ist die Entität, die unter dem Pseudonym "Sharky6999" agiert und durch die Blockchain-Adresse 0x751a2b86cab503496efd325c8344e10159349ea1 repräsentiert wird.[5]

Die vorliegende Untersuchung liefert eine detaillierte, technisch exhaustive und quantitative Analyse dieses spezifischen Traders und dekonstruiert die zugrunde liegenden algorithmischen Strategien, mit einem besonderen Fokus auf die Ausnutzung von Oracle-Verzögerungen (Oracle Delay Latency Arbitrage).[7] Darüber hinaus wird ein umfassender Leitfaden zur Architektur, Infrastruktur und Latenzoptimierung für professionelle Polymarket-Handelssysteme präsentiert. Hierbei werden Netzwerkspezifika, Server-Kolokation, Linux-Kernel-Bypass-Technologien, das Management von Mempool-Dynamiken sowie fortgeschrittene Transaktionsmanagement-Paradigmen auf der Polygon-Blockchain tiefgehend und in professioneller Tiefe beleuchtet, um die Anforderungen an den Aufbau und Betrieb derartiger Systeme strukturiert darzulegen.

Dekonstruktion des Traders "Sharky6999" (0x751a2b86cab503496efd325c8344e10159349ea1)

Eine tiefgehende forensische On-Chain-Analyse der auf Polygonscan verfügbaren Daten offenbart, dass es sich bei der Adresse 0x751a2b86caB503496eFD325c8344E10159349eA1 nicht um eine gewöhnliche Externally Owned Account (EOA) Wallet eines manuellen Händlers handelt, sondern um einen komplexen Smart Contract.[5] Spezifisch handelt es sich um einen Gnosis Safe Proxy Contract, der vor über einem Jahr (im Januar 2025) durch die "Polymarket : Safe Proxy Factory" (Adresse 0xaacfeea03eb1561c4e67d661e40682bd20e3541b) instanziiert wurde.[5] Diese architektonische Entscheidung ist fundamental für die Ausführungsstrategie des Traders und bildet das Fundament für die spätere Analyse der Gas-Optimierung.

Portfolioallokation und Finanzielle Metriken

Zum Zeitpunkt der Datenerfassung weist das Portfolio dieses Contracts eine bemerkenswerte und hochliquide Kapitalisierung auf. Die primäre Liquidität wird in Form von Bridged USD Coin (USDC.e) gehalten, dem Standard-Sicherheitstoken (Collateral) auf der Polymarket-Plattform.[5] Der Bestand beläuft sich auf exakt 899.727,739821 USDC.e, was aufgrund der Koppelung an den US-Dollar einer nahezu exakten 1:1-Äquivalenz in Fiat-Währung entspricht.[5]

Zusätzlich verfügt der Contract über 110,87 POL (ehemals MATIC, dem nativen Gas-Token der Polygon-PoS-Chain), bewertet mit etwa 10,22 USD zum Kurs von 0,09 USD pro POL.[5] Das Vorhandensein einer relativ geringen Menge an nativem Gas-Token ist darauf zurückzuführen, dass Polymarket für Gnosis Safe Wallets einen Meta-Transaction-Relayer nutzt, der gasfreie Transaktionen für Nutzer ermöglicht, solange die Operationen innerhalb des Polymarket-Ökosystems stattfinden.[5] Das Portfolio umfasst insgesamt 113 Token, darunter auch 33 Non-Fungible Tokens (NFTs), wie beispielsweise die "Pastel Strawberry Porcelain Doll" (PSPD), was auf zusätzliche Interaktionen jenseits des reinen Tradings oder auf Airdrop-Allokationen hindeuten könnte.[5] Das Multichain-Portfolio wird auf insgesamt 899.737,96 USD beziffert.[5]

Das kumulierte Handelsvolumen dieses Akteurs summiert sich auf über 98 Millionen US-Dollar, das über verschiedene Anlageklassen hinweg abgewickelt wurde, wobei hochliquide kurzfristige Kryptowährungsmärkte wie Bitcoin (BTC), Ethereum (ETH), Solana (SOL) und Ripple (XRP) deutlich dominieren.[6] Aus diesem enormen Volumen resultierte ein realisierter, kumulierter Profit von rund 534.000 US-Dollar.[6] Diese Diskrepanz zwischen Volumen und absolutem Profit unterstreicht die Natur des Hochfrequenzhandels: Die Profitmarge pro Trade ist extrem marginal (oft im Promillebereich), doch durch die extrem hohe Frequenz und das Recycling des Kapitals akkumulieren sich signifikante Gewinne.

Statistische Anomalien und die 97-Prozent-Trefferquote

Die aus analytischer Sicht bemerkenswerteste und aufschlussreichste statistische Metrik dieses Traders ist die historische Trefferquote (Win Rate) von 97 %.[6] Um diese Zahl in den korrekten Kontext zu setzen, muss die Struktur von Prognosemärkten betrachtet werden. Polymarket ist darauf ausgelegt, binäre oder diskrete Ereignisse (z. B. Wahlen, Sportergebnisse, Krypto-Preisziele) zu handeln, wobei die Preise der "YES"- und "NO"-Anteile die vom Markt

aggregierte Wahrscheinlichkeit des Eintretens reflektieren.[3] Ein effizienter Markt tendiert dazu, unvorhersehbare Ereignisse als 50/50-Szenarien (oder entsprechend der echten Eintrittswahrscheinlichkeit) zu bepreisen.[6]

In derartigen stochastischen Systemen ist eine Trefferquote von 97 % durch direktionale Wetten, fundamentale Analyse oder überlegene Marktprognosen mathematisch und statistisch unmöglich. Selbst die fortschrittlichsten Hedgefonds und prädiktiven KI-Modelle erreichen bei unvorhersehbaren Ereignissen kaum Trefferquoten jenseits der 60 %. Auch traditionelle Arbitrage-Bots, die Preisdifferenzen zwischen verschiedenen Plattformen (z. B. Kalshi vs. Polymarket) oder ineffiziente Orderbücher ausnutzen, erzielen typischerweise Trefferquoten im Bereich von rund 70 %.[6]

Eine konstante Trefferquote von 97 % bei einer durchschnittlichen Positionsgröße von 74.000 US-Dollar indiziert daher zweifelsfrei, dass das System keine Prognosen im semantischen Sinne trifft.[6] Es basiert auf absoluter, deterministischer Informationsasymmetrie. Es gibt keine Evidenz für Front-Running von EOA-Transaktionen im klassischen DeFi-Sinne oder simple Cross-Exchange-Arbitrage als primäre Ertragsquelle.[6] Stattdessen belegt diese Metrik, dass das System mikrosekundengenaue Latenzvorteile nutzt, um den Ausgang von Ereignissen zu handeln, die in der realen Welt bereits stattgefunden haben und als objektiver Fakt feststehen, aber noch nicht in den Smart Contracts oder dem Orderbuch (CLOB) von Polymarket reflektiert wurden.[6] Dieses Vorgehen wird als Informationsarbitrage oder spezifisch als "Oracle Delay Latency Arbitrage" bezeichnet.[7]

Smart Contract Architektur: Gnosis Safe und Transaktionsmechanik

Die Interaktion des Traders mit dem Polymarket-Netzwerk erfolgt nicht durch direkte Signierung von Trades von einer EOA, sondern fast ausschließlich über die Funktion execTransaction des Gnosis Safe Proxy Contracts.[5] Die Transaktionshistorie auf Polygonscan zeigt eine fortlaufende Kette von Exec Transaction-Aufrufen, die von verschiedenen Relayer-Adressen initiiert werden.[5] Die Nutzung eines Gnosis Safe Wallets bietet für algorithmische Händler auf Polymarket signifikante architektonische Vorteile:

Feature	EOA (Standard Wallet)	Safe Wallet (Gnosis Proxy)
Gasgebühren	Nutzer zahlt On-Chain-Gebühren (POL)	Gasless (über Polymarket Relayer)
Komplexität	Simpel, direkte Signatur	Erfordert Deployment via Relayer Client

Erweiterte Features	Basis-Trading, einzelne Tx	Batched Transactions, Contract Logic
Signature Type ID	0	2 (EIP-712 Contract Signatures)
Vergleich der Wallet-Architekturen auf Polymarket. [11]		

Die Gnosis-Safe-Architektur basiert auf einem Proxy-Pattern. Der Contract enthält eine fallback-Funktion, die als external payable deklariert ist und alle eingehenden Transaktionen mittels delegatecall an einen zentralen singleton (MasterCopy) Contract weiterleitet.[5] Dies ermöglicht die Ausführung komplexer Logik unter Beibehaltung des Zustands im Proxy-Contract und senkt die Deployment-Kosten.[5]

Für den Hochfrequenzhandel ist das Feature der "Batched Transactions" (gebündelte Transaktionen) von immenser Bedeutung.[10] Ein Bot kann mehrere Handelsoperationen – wie beispielsweise das Setzen mehrerer Limit-Orders auf verschiedenen Preisniveaus, das Zusammenführen von Positionen (Merge), das Einlösen von Gewinnen (Redeem) und das Transferieren von Sicherheiten – in einer einzigen, atomaren Blockchain-Transaktion zusammenfassen.[10] Dies garantiert, dass entweder alle logischen Schritte erfolgreich ausgeführt werden oder die gesamte Transaktion fehlschlägt (Revert), was das Risiko partieller Ausführungen eliminiert.

Die Gas-Overhead-Kosten für solche Transaktionen sind komplex strukturiert. Jedes Non-Zero-Byte in den Transaktionsdaten (Calldata) kostet das Netzwerk 16 Gas, während Zero-Bytes mit 4 Gas berechnet werden.[14] Die Verifikation der ECDSA-Signatur für die execTransaction erfordert zusätzlich einen Overhead von etwa 7.000 Gas (1.000 für die Signaturdaten und 5.000 bis 6.000 für die kryptografische Prüfung).[14] Durch das Batching von Trades amortisiert Sharky6999 diese fixen Verifikationskosten über ein großes Volumen an Operationen. Obwohl Polymarket die Gasgebühren über den Relayer subventioniert, schützt eine gasoptimierte Ausführung den Bot davor, vom Relayer wegen exzessiven Ressourcenverbrauchs gedrosselt zu werden, und ermöglicht eine schnellere Propagierung im Mempool.[10]

Die Anatomie der Latenzarbitrage und Oracle-Verzögerungen

Um die Profitabilität von Akteuren wie Sharky6999 reproduzieren zu können, ist ein tiefes Verständnis der Marktmikrostruktur von Polymarket und der Funktionsweise des zugrunde liegenden Oracles unerlässlich. Der Kern der Strategie beruht auf der Ausnutzung der

temporären Diskrepanz zwischen der realen Welt und der On-Chain-Realität.[7]

Das UMA Optimistic Oracle und der Resolution-Zyklus

Dezentrale Prognosemärkte benötigen einen Mechanismus, um reale Ereignisse (wie das Ergebnis eines Fußballspiels oder den Preis von Bitcoin zu einem bestimmten Zeitpunkt) vertrauenslos und manipulationssicher auf die Blockchain zu übertragen. Polymarket nutzt hierfür das UMA (Universal Market Access) Optimistic Oracle (OO).[15]

Im Gegensatz zu kontinuierlichen Preis-Feeds, wie sie beispielsweise von Chainlink für DeFi-Lending-Plattformen bereitgestellt werden und bei jeder Block-Iteration Preise pushen, arbeitet das UMA-Oracle nach einem Request-Propose-Dispute-Zyklus.[15] Es ist "optimistisch", weil vorgeschlagene Ergebnisse als gültig angenommen werden, sofern sie nicht innerhalb einer definierten Frist angefochten werden.[15] Dieser anfragegesteuerte Ansatz minimiert unnötige On-Chain-Transaktionen und skaliert hervorragend für binäre oder intersubjektive Daten.[15]

Der Resolution-Zyklus (Abwicklungszyklus) eines Marktes verläuft in streng definierten Phasen:

1. **Proposal (Vorschlag):** Sobald das Enddatum eines Marktes erreicht ist, kann jeder Netzwerkteilnehmer ein Ergebnis vorschlagen. Hierfür wählt der Proposer das gewinnende Ergebnis (z. B. "YES") und muss eine Kaution (Bond) hinterlegen, die typischerweise 750 USDC.e beträgt.[16] Ist der Vorschlag korrekt, erhält der Proposer seine Kaution zuzüglich einer Belohnung zurück. Ist er falsch, wird der Bond konfisziert.[16]
2. **Challenge Period (Herausforderungsfrist):** Nach dem Einreichen des Vorschlags beginnt eine Frist von regulär zwei Stunden. In dieser Zeit kann jeder andere Netzwerkteilnehmer das Ergebnis anfechten (Dispute).[16]
3. **Resolution (Abwicklung) oder Escalation (Eskalation):** Bleibt das Ergebnis zwei Stunden lang unangefochten, wird der Markt abgewickelt (Resolved) und die Inhaber der Gewinner-Tokens können diese für 1,00 USD pro Anteil einlösen, während Verlierer-Tokens wertlos werden.[9] Kommt es zu einem Dispute, beginnt eine zweite Vorschlagsrunde. Bei einem erneuten Dispute eskaliert die Entscheidung an das DVM (Data Verification Mechanism) von UMA, wo Token-Inhaber in einem Votumsverfahren über das Ergebnis abstimmen.[16]

Dieser Prozess garantiert Dezentralität und Sicherheit, führt jedoch zu einer systembedingten Verzögerung. Für den Hochfrequenzhandel ist jedoch nicht die zweistündige Dispute-Phase der Angriffsvektor, sondern die Millisekunden-Latenz im Orderbuch (CLOB) kurz vor oder exakt zum Zeitpunkt des Marktend-Ereignisses.

Das Arbitrage-Fenster in kurzfristigen Märkten

Das Phänomen der Oracle Delay Latency Arbitrage manifestiert sich am extremsten in kurzfristigen Kryptowährungsmärkten, wie beispielsweise "Wird Bitcoin in den nächsten 5

Minuten über 65.000 USD steigen?".[12] In derartigen hochfrequenten Märkten orientiert sich das User Interface (UI) von Polymarket an externen Datenströmen. Wenn der Spot-Preis von Bitcoin auf großen zentralisierten Börsen (CEX) wie Binance oder Coinbase das Zielniveau erreicht, vergeht eine marginale, aber messbare Zeitspanne, bis diese Information in den Orderbüchern von Polymarket vollständig eingepreist ist und Marktteilnehmer ihre Orders aktualisieren.[7]

Analysen der Architektur von Systemen wie "PolyCue" oder "PolySnipe" zeigen, dass fortgeschrittene HFT-Bots direkte, ultra-low-latency WebSocket-Verbindungen zu den primären Krypto-Börsen oder dedizierten Chainlink-Knoten aufrechterhalten.[7] Wenn der Bitcoin-Preis die definierte Schwelle überschreitet, weiß der Algorithmus objektiv und deterministisch, dass der Markt unweigerlich mit "YES" auflösen wird.[7]

Zu diesem exakten Zeitpunkt bietet das Polymarket-Orderbuch jedoch häufig noch "YES"-Anteile zu Preisen weit unter 1,00 USD an (z. B. zu 0,62 USD), da langsame Market Maker oder private Trader ihre passiven Limit-Orders noch nicht storniert haben.[7] Es entsteht ein kritisches Zeitfenster von historisch 2 bis 15 Sekunden.[7] Ein Latenz-Bot exekutiert in diesem Moment aggressive Market Orders, um die verbleibende Liquidität im Orderbuch restlos aufzukaufen.[7] Er erwirbt damit deterministisch gewinnende Anteile, die wenig später, nach Durchlaufen des UMA-Resolution-Prozesses, für 1,00 USD eingelöst werden können.[8] Ein Kauf zu 0,62 USD generiert somit eine risikofreie Arbitrage-Rendite von 0,38 USD pro Anteil. Da sich diese Ineffizienzen extrem schnell schließen, ist die Ausführungsgeschwindigkeit der absolut kritische Erfolgsfaktor. Die durchschnittliche Dauer einer Arbitrage-Möglichkeit auf Polymarket sank von noch 12,3 Sekunden im Jahr 2024 auf lediglich 2,7 Sekunden im Jahr 2026.[7] Daten belegen, dass 73 % dieser Arbitrage-Profite von Bots absorbiert werden, die Ausführungszeiten von unter 100 Millisekunden (Sub-100ms) vom Signal bis zur On-Chain-Ausführung erreichen.[7]

Das Central Limit Order Book (CLOB) und taktische Order-Typen

Die Extraktion dieses Wertes erfordert den präzisen und fehlerfreien Einsatz der Polymarket CLOB API.[4] Polymarket wickelt Trades nicht über einen Automated Market Maker (AMM) mit einer Bonding Curve ab, sondern betreibt ein voll funktionsfähiges, Off-Chain-Matching-basiertes, aber On-Chain-gesettletes Orderbuch, in dem alle Outcomes (YES/NO) eigenständige Orderbücher besitzen.[3] Alle Orders auf Polymarket sind technisch Limit-Orders, die als EIP-712-Strukturen formatiert, kryptografisch gehasht und signiert, und schließlich vom Exchange-Smart-Contract auf Polygon abgewickelt werden.[19]

Um Latenzarbitrage zu betreiben, agieren HFT-Bots ausschließlich als "Taker", die dem Orderbuch aggressiv Liquidität entziehen. Das API-Design von Polymarket stellt hierfür spezifische Order-Typen zur Verfügung, deren Verhalten essenziell für das Risikomanagement des Bots ist:

Order-Typ	Abkürzung	Verhalten auf CLOB	Primärer HFT-Anwendungsfall
Good-Til-Cancelled	GTC	Ruht im Orderbuch bis zur Ausführung oder Stornierung durch den Nutzer.	Passive Market-Making-Strategien (Maker). Hohes Risiko für "Toxic Flow" durch Latenz-Bots.
Good-Til-Date	GTD	Ruht im Orderbuch bis zu einem spezifischen Zeitstempel (UTC-Sekunden).	Event-gesteuertes Expiry-Management. Auto-Stornierung vor Bekanntgabe von News.
Fill-Or-Kill	FOK	Muss sofort und vollständig ausgeführt werden. Bei unzureichender Liquidität wird die Order komplett abgelehnt.	Aggressive Latenzarbitrage. All-or-nothing Ausführung zur Vermeidung partieller Fills.
Fill-And-Kill	FAK	Führt sofort alle verfügbaren Anteile zum Zielpreis aus. Der nicht ausführbare Rest wird sofort storniert.	Liquiditätsabschöpfung bei hoher Volatilität. Akzeptanz von Teilausführungen.
Spezifikation der Limit-Order-Typen auf der Polymarket CLOB API. [19]			

Ein professioneller Arbitrage-Bot, der eine Oracle-Verzögerung ausnutzt, verwendet primär FOK- oder FAK-Orders.[19] Wenn der Bot das Signal empfängt, dass Bitcoin das Preisziel erreicht hat, sendet er eine FAK-Order für das maximale Zielvolumen (z. B. 50.000 USD). FAK garantiert,

dass der Bot in Millisekunden alle verfügbaren Anteile bis zu seinem Limit-Preis aufkauft, ohne dass Reste der Order im Orderbuch (als GTC) verbleiben.[19] Verbliebe die Order im Buch, bestünde das Risiko, dass der Markt sich dreht oder das Kapital gebunden ist, während andere Opportunitäten entstehen.

Darüber hinaus unterstützt die API "Post-Only Orders". Diese Limit-Orders stellen sicher, dass sie niemals sofort ausgeführt werden (also keinen Taker-Status annehmen), was Market Makern hilft, Gebühren zu sparen, da Maker in der Regel Rabatte (Rebates) erhalten, während Taker Gebühren zahlen müssen.[19]

Fortgeschrittene algorithmische Strategien jenseits der puren Latenz

Während die Oracle Delay Arbitrage die spektakulärsten Trefferquoten liefert (wie die 97 % von Sharky6999 [6]), hat sich das Marktumfeld bis 2026 stark gewandelt. Die Ära, in der Anfänger mit simplen Skripten risikofreie Arbitrage betreiben konnten, ist beendet.[7] Der mediane Arbitrage-Spread ist auf 0,3 % gesunken, was nach Berücksichtigung der Netzwerk-Gasgebühren kaum noch profitabel ist.[7]

Folglich generieren hochentwickelte Systeme mittlerweile 27 % ihrer Profite aus nicht-arbitragebasierten Strategien, die in Multi-Strategie-Portfolios gebündelt werden.[7] Diese Strategien erfordern ein höheres Maß an mathematischer Modellierung und Marktmikrostruktur-Verständnis:

1. **Market Rebalancing Arbitrage:** Diese Strategie operiert innerhalb eines einzelnen Marktes. Da Polymarket YES- und NO-Tokens als separate Orderbücher führt, müssen die impliziten Preise von YES und NO addiert stets exakt 1,00 USD ergeben.[3] Wenn beispielsweise in einem volatilen Marktumfeld YES durch aggressive Käufer auf 0,48 USD getrieben wird und NO durch unabhängige Orderbuch-Dynamiken bei 0,50 USD verharrt, summiert sich der Preis auf 0,98 USD.[3] Ein Bot, der beide Seiten simultan kauft, garantiert sich eine Auszahlung von 1,00 USD bei Fälligkeit und erzielt einen risikofreien Profit von 0,02 USD pro Anteil.[3]
2. **Combinatorial Arbitrage (Kombinatorische Arbitrage):** Diese komplexe Variante nutzt logische Inkonsistenzen zwischen verwandten Märkten aus.[3] Wenn Event A lautet "Gewinnt Kandidat X die Wahl?" und Event B lautet "Gewinnt Kandidat X den Bundesstaat Y?", und die historische Korrelation bedingt, dass X ohne Y nicht gewinnen kann, der Prognosemarkt diese Wahrscheinlichkeiten aber durch isoliertes Retail-Trading de-korreliert bepreist, identifizieren und exploitieren Algorithmen diese Diskrepanz über Matrix-Kalkulationen.[3]
3. **Tail-End Trading:** In Märkten, die sich der Auflösung nähern und deren Ausgang nahezu sicher ist (z. B. YES bei 0,99 USD), neigen Retail-Investoren dazu, ihre Positionen vorzeitig zu liquidieren, um Kapital freizumachen, anstatt auf die UMA-Resolution zu warten.[3] Bots

absorbieren diese Verkäufe systematisch zu 0,98 USD oder 0,99 USD und realisieren eine kleine, aber hochsichere Rendite über die verbleibende Laufzeit.[3]

Ein kritischer Fehler, der in Diskussionen über Copy-Trading und unregulierte Bots (wie in Discord-Gruppen oder Reddit-Foren) häufig dokumentiert wird, ist die Verwechslung von "Gross Edge" (Bruttovorteil) und "Net Edge" (Nettovorteil).[24] Wenn ein Bot eine Arbitrage-Möglichkeit von 2 % identifiziert, ignoriert der unerfahrene Entwickler oft Taker-Gebühren, den Bid-Ask-Spread und vor allem Slippage.[25] In extrem kurzfristigen Märkten (5 bis 15 Minuten) vernichten diese Transaktionskosten den Erwartungswert (Expected Value) vollständig.[25] Zudem wird oft eine Fill-Rate von 100 % in Backtests angenommen, während die Realität auf Polymarket aufgrund massiver HFT-Konkurrenz und "Thin Liquidity Traps" (Illiquidität bei größeren Orders) oft bei einer Fill-Rate von lediglich 30 % liegt.[25]

Softwarearchitektur professioneller Polymarket-Trading-Bots

Um in diesem hochkompetitiven Ökosystem zu bestehen, reicht ein einfaches Python-Skript, das in einer Endlosschleife REST-APIs abfragt, nicht aus. Die Architektur professioneller Systeme erfordert eine multiphasige, modular aufgebaute und auf Mikrosekunden optimierte Pipeline.[12]

Programmiersprachen und Nebenläufigkeit (Concurrency)

Während Python aufgrund seiner Data-Science-Bibliotheken (wie pandas oder numpy) und der umfangreichen Polymarket-Python-SDKs für das Prototyping und das Backtesting sehr beliebt ist, scheitert es im produktiven Hochfrequenzhandel oft an der Global Interpreter Lock (GIL) und der langsameren Ausführungsgeschwindigkeit. Professionelle Systeme, wie der in Entwicklerkreisen dokumentierte "PolySnipe"-Bot, werden häufig in kompilierten Sprachen wie Go (Golang) oder Rust neu geschrieben.[12]

Die Migration auf Go ermöglicht die Nutzung von Goroutines für hochgradig parallele Verarbeitung. Das System kann Hunderte von WebSocket-Streams simultan überwachen und Order-Generierungen ohne blockierende I/O-Operationen durchführen.[12] Entwickler berichten, dass die Reaktionszeit der Kernschleife (Feed überwachen $\rightarrow$ Signal detektieren $\rightarrow$ Ausführen) von Sekunden auf wenige Millisekunden reduziert werden konnte, was in 5-Minuten-BTC-Märkten den Unterschied zwischen Profit und Verlust bedeutet.[12]

Dateninjektion: Das Primat von WebSockets über REST

Ein fundamentaler Architekturfehler von Anfängersystemen ist das Polling (die periodische Abfrage) der REST-API.[12] Die CLOB-API von Polymarket limitiert REST-Anfragen massiv, um die Infrastruktur vor DDoS-ähnlichen Überlastungen zu schützen. Nach den Spezifikationen von

2026 gelten folgende Rate-Limits:

- GET /price (Abfrage des aktuellen Preises): Limitiert auf 100 Anfragen pro 10 Sekunden.[22]
- GET /book (Abfrage des Orderbuchs): Limitiert auf 50 Anfragen pro 10 Sekunden.[22]
- POST /order (Erstellung einer Order): Limitiert auf 500 Anfragen pro 10 Sekunden.[22]
- Die Data-API (für historische Trades und Positionen) ist bei GET /trades auf 200 Anfragen pro 10 Sekunden limitiert.[28]

Ein System, das im Millisekundentakt das Orderbuch für dutzende Märkte abfragt, wird unweigerlich sofort geblockt. Stattdessen müssen WebSocket-Verbindungen zwingend für die Dateninjektion genutzt werden.[12] Polymarkets US-Retail-API (welche 2026 nicht mehr geoblocked ist) stellt hierfür hochperformante Endpunkte bereit [27]:

- /v1/ws/markets: Streamt Echtzeit-Marktdaten für bis zu 10 Instrumente simultan. Dies pusht Deltas (Änderungen) des Orderbuchs sofort an den Client, anstatt den gesamten Zustand wiederholt herunterzuladen.[27]
- /v1/ws/private: Übermittelt latenzfreie Updates zu eigenen Ausführungen (Fills), Order-Status und Balance-Änderungen.[27]

Das lokale Orderbuch wird im RAM des Servers gepflegt (mittels optimierter Binärbäume oder spezialisierter Hash-Maps), sodass die Entscheidungsebene des Bots in konstanter Zeit $\mathcal{O}(1)$ den besten Bid/Ask-Spread auslesen kann, ohne auf das Netzwerk warten zu müssen.

Multi-Model AI Ensemble für nicht-deterministische Märkte

Neben der deterministischen Latenzarbitrage erschließen hochprofessionelle Systeme ineffiziente, langfristigere Märkte durch automatisierte Forschung und stochastische Wahrscheinlichkeitsberechnung. Ein Referenzmodell für diese Architektur ist der Open-Source "Fully-Autonomous-Polymarket-AI-Trading-Bot" des Entwicklers *Dylanpersonguy*.[29]

Dieses System verzichtet auf manuelle Dateneingabe und implementiert eine 10-stufige Pipeline [29]:

1. **Market Discovery (Marktentdeckung):** Der Bot scannt die Polymarket Gamma API. Über die Konfigurationsdatei config.yaml werden Filter angewendet: Mindestvolumen von 1.000 USD, Mindestliquidität von 500 USD, maximaler Spread von 0,08 USD und eine maximale Laufzeit von 120 Tagen. Präferierte Kategorien sind Makroökonomie, Wahlen, Technologie und Wissenschaft.[29]
2. **Klassifikation und Pre-Research Filtering:** Märkte werden durch über 100 Regex-Regeln ohne kostenintensive LLM-Aufrufe klassifiziert. Ein Scoring-System (Minimum-Score von 25) filtert "Junk-Märkte" heraus.[29]
3. **Automated Research Engine:** Das System baut Suchanfragen auf (z. B. domänenspezifische Suchen wie site:bls.gov für Inflationsdaten) und nutzt APIs wie

SerpAPI oder Tavily. Es extrahiert vollständiges HTML via BeautifulSoup und bewertet die Domain-Autorität, um primäre Quellen über soziale Medien zu priorisieren.[29]

4. **Multi-Model Ensemble Forecasting:** Das Herzstück für Vorhersagen ist ein parallelisiertes Ensemble von Frontier Large Language Models (LLMs). Die Gewichtung ist wie folgt konfiguriert:
   - **GPT-4o:** 40 % Gewichtung.[29]
   - **Claude 3.5 Sonnet:** 35 % Gewichtung.[29]
   - **Gemini 1.5 Pro:** 25 % Gewichtung.[29]
5. **Calibration und Edge Calculation:** Die Modelle arbeiten unabhängig voneinander (LLM-Temperatur auf 0,2 für Konsistenz). Die Resultate werden mittels getrimmtem Mittelwert (Trimmed Mean) aggregiert. Das System nutzt Platt-Skalierung (Platt Scaling), um die Wahrscheinlichkeiten zu kalibrieren, und misst die Leistung der Modelle kontinuierlich über den Brier-Score (eine Metrik zur Evaluation probabilistischer Vorhersagen). Der "Net Edge" (Nettovorteil) wird kalkuliert, indem die Modellwahrscheinlichkeit mit der impliziten Marktwahrscheinlichkeit verglichen wird (ein Mindest-Edge von 0,04 ist für einen Trade erforderlich).[29]

Risikomanagement und Position Sizing Engine

Der identifizierte mathematische Vorteil wird an die Risikomanagement-Engine übergeben, welche entscheidet, ob und mit welchem Kapitalvolumen ein Trade ausgeführt wird. Professionelle Bots wie der beschriebene unterziehen potenzielle Trades über 15 unabhängigen Risikoprüfungen.[29]

Die mathematische Grundlage für die Positionsgrößenbestimmung (Position Sizing) ist das Kelly-Kriterium, welches das Kapitalwachstum maximiert und das Ruinrisiko minimiert.[7] Die klassische Formel lautet:

$$f^* = \frac{p \cdot b - q}{b}$$

Da reine Kelly-Wetten in hochvolatilen Krypto-Prognosemärkten zu unakzeptablen Drawdowns führen, nutzt das System "Fractional Kelly". Die config.yaml definiert eine kelly_fraction von 0,25 (ein Viertel Kelly) bezogen auf die konfigurierte Bankroll (z. B. 5.000 USD).[29]

Diese Basis-Positionsgröße wird dynamisch durch bis zu sieben Multiplikatoren adjustiert. Ein "Market Regime Detector" klassifiziert die aktuellen Marktbedingungen in Echtzeit (Normal, Trending, High Volatility, Low Activity) und drosselt das Risiko in volatilen Phasen.[29] Das Portfolio-Exposure ist strikt limitiert: Maximal 35 % Kapitalbindung pro Kategorie, maximal 25 % für ein einzelnes Ereignis, und maximal 50 USD pro Markt (max_stake_per_market).[29]

Zusätzlich implementieren Enterprise-Bots ein 4-stufiges Drawdown-Heat-System. Erreicht der kumulierte Verlust 10 %, wird eine Warnung ausgelöst. Bei 20 % Drawdown greift ein "Kill Switch", der den Bot-Motor hart stoppt, alle offenen Positionen auflöst und weitere

CLOB-Interaktionen blockiert, um Softwarefehler abzufedern.[29]

"Smart Money Intelligence" und Copy-Trading-Pipelines

Ein weiteres architektonisches Paradigma ist das systematische Extrahieren von Schwarmintelligenz. Das System implementiert einen "Whale Scanner", der Top-Wallets auf dem Polymarket-Leaderboard überwacht (ähnlich der Strategie von Novus-Tech-LLC Copy Trading Bots).[29] Über eine 7-phasige Pipeline (Leaderboard $\rightarrow$ Markets $\rightarrow$ Global Trades $\rightarrow$ Market Trades $\rightarrow$ Ranking $\rightarrow$ Analysis) berechnet das System alle 15 Minuten einen Smart Money Index (SMI) für bis zu 20 überwachte Wallets.[29]

Wenn das System erkennt, dass eine signifikante Anzahl dieser hochrangigen Trader kongruente Positionen aufbaut, generiert es ein "Conviction Signal". Dieses Signal addiert einen conviction_edge_boost (z. B. 0,08) zum kalkulierten Edge des eigenen Systems, was die Fraktion des eingesetzten Kapitals erhöht.[29] Für Beobachter erklärt dieser Mechanismus, warum Copy-Trading (wie auf Plattformen und in Discord-Gruppen diskutiert) manuell oft scheitert (UI-Lag, Slippage) [25], aber in einer vollautomatisierten, API-getriebenen Pipeline als wertvoller Verstärker (Alpha-Booster) fungiert.

Hardware-Infrastruktur, Netzwerk-Stack und Server-Kolokation

Die raffinierteste Software-Architektur und die präzisesten mathematischen Modelle sind im Hochfrequenzhandel wertlos, wenn die physikalische Netzwerkinfrastruktur Flaschenhälse aufweist.[33] In Latenzarbitrage-Szenarien, in denen Hunderte von Bots identische Arbitrage-Gelegenheiten (wie den Ausbruch des Bitcoin-Preises) im Millisekundenbereich erkennen, gewinnt ausschließlich die Entität, deren TCP/IP-Pakete als Erste den Matching-Engine-Server der Börse erreichen.[7] Ein historisches Beispiel belegt, dass eine Latenzverzögerung von lediglich 47 Millisekunden (weniger als ein Wimpernschlag) in Krypto-Arbitrage-Systemen Opportunitätskosten von rund 180.000 USD jährlich verursachen kann; ein Infrastruktur-Upgrade für 220.000 USD, das die Latenz von 89ms auf 42ms reduzierte, zahlte sich innerhalb von sechs Monaten durch eine Erhöhung der Trefferquote von 23 % auf 61 % aus.[34]

Server-Lokation und AWS-Kolokation (London)

Die Lichtgeschwindigkeit diktiert die harte physikalische Schranke der Latenz. Polymarket wickelt das Settlement zwar dezentral auf Polygon ab, das Orderbuch (CLOB API) wird jedoch zentralisiert gehostet, um die Performance zu gewährleisten. Die primäre Infrastruktur für Polymarkets Orderbuch befindet sich in London.[26]

Ein Händler, der seinen Bot auf einem VPS in Tokio oder New York betreibt, erfährt physikalische

Round-Trip-Zeiten (RTT) von 70 bis über 150 Millisekunden. Für HFT ist dies unakzeptabel. Professionelle Händler mieten daher Bare-Metal-Server in Londoner Colocation-Zentren (wie LD4, einem globalen Hub für Finanz-HFT) oder nutzen Instanzen in der AWS-Region eu-west-2 (London), da gemutmaßt wird, dass Polymarket Teile seiner Infrastruktur ebenfalls bei AWS betreibt.[26] Das Spoofen von IP-Adressen für Nutzer aus geo-geblockten Regionen (wie Londoner Bürgern selbst) ist eine technische Hürde, die institutionelle Akteure durch den Einsatz eigener /24-IPv4-Blöcke (Bring Your Own IP) und dedizierte Netzwerke umgehen.[26]

Bei der Auswahl der Hardware (z. B. AWS EC2) werden General-Purpose-Instanzen wie die T2-Familie kategorisch gemieden. Diese basieren auf einer CPU-Gutschrift-Logik (Burstable Performance) und drosseln den Takt unter anhaltender Last, was zu fatalen Latenzspitzen (Jitter) führt.[37] HFT-Systeme greifen stattdessen auf rechenoptimierte (Compute Optimized) oder hochfrequente Instanzen zurück, wie die M6i, M6in oder die extrem hoch getaktete z1d-Familie, die eine konsistente Kernfrequenz von über 4,0 GHz ohne Throttling garantieren.[36] Die Konfiguration in "Cluster Placement Groups" minimiert zudem die Anzahl der Netzwerk-Hops innerhalb des Rechenzentrums, wodurch Tick-to-Trade-Latenzen im niedrigen zweistelligen Mikrosekundenbereich ermöglicht werden.[39] Alternative Provider für Bare-Metal wie RedSwitches, BSO, Avelacom oder Beeks werden ebenfalls intensiv für HFT genutzt.[33]

Betriebssystem-Tuning und Linux-Kernel-Bypass

Selbst auf der schnellsten Server-Hardware induziert der Standard-Netzwerk-Stack des Linux-Betriebssystems erhebliche Latenzen. Der herkömmliche Weg eines Netzwerkpakets verläuft wie folgt: Das Paket erreicht die Network Interface Card (NIC), diese sendet einen Interrupt Request (IRQ) über den PCIe-Bus an die CPU.[41] Der Kernel unterbricht die laufenden User-Space-Programme (Context Switch), kopiert die Paketdaten vom Kernel-Space in den User-Space und übergibt sie an die Socket-Buffer, woraufhin der Scheduler die Trading-Applikation reaktiviert.[41] Dieser hochkomplexe Prozess erfordert wertvolle Mikrosekunden und verursacht unvorhersehbare Latenzschwankungen.

Um diese Limitationen auszuhebeln, setzen Quantitative Entwickler auf "Kernel Bypass"-Technologien.[33]

1. **DPDK (Data Plane Development Kit):** Ein von Intel entwickeltes Framework, das es der Applikation ermöglicht, direkt auf die Register und Speicherpuffer der Netzwerkkarte zuzugreifen.[41] Die NIC wird in einen Polling-Modus versetzt. Spezifische CPU-Kerne werden vom Linux-Scheduler komplett isoliert (CPU Isolation) und tun nichts anderes, als in einer Endlosschleife (ohne Interrupts) auf neue Pakete zu warten. Memory-Copies entfallen zu 100 %.[41]
2. **RDMA (Remote Direct Memory Access) & AF_XDP:** RDMA ermöglicht es zwei Systemen, Daten direkt aus dem RAM des anderen zu lesen, ohne Beteiligung des Betriebssystems. AF_XDP ist eine Linux-native Methode, um Pakete im untersten Treiber-Layer abzufangen.[42]

Begleitend zur Software müssen Hardware-Parameter (BIOS) modifiziert werden. C-States (Stromsparfunktionen der CPU) werden vollständig deaktiviert, um Aufwach-Latenzen zu verhindern.[33] Die NUMA-Topologie (Non-Uniform Memory Access) wird strikt beachtet: Die Trading-Software wird an die CPU-Kerne gebunden, die physikalisch mit demselben Speichercontroller und demselben PCIe-Slot der NIC verbunden sind, um Datenwege über den langsameren QPI (QuickPath Interconnect) Bus zu verhindern.[33] Ausgestattet mit High-Performance NICs (z. B. NVIDIA ConnectX-6) oder Field Programmable Gate Arrays (FPGAs) für die Hardware-Decodierung von Marktdaten, erreichen Top-Tier-Firmen Latenzen im einstelligen Mikrosekundenbereich.[42]

On-Chain-Execution: RPC-Knoten, BDN und Polygon-Spezifika

Der Handel auf Polymarket umfasst zwei Sphären: Das schnelle CLOB für das Matching und die langsame, asynchrone Polygon-Blockchain für das Settlement (Einlösen von Gewinnen, Smart Contract Interaktionen, Oracle-Vorschläge).[3]

Evaluierung von Polygon RPC-Providern

Das Senden von Transaktionen oder das Lesen von On-Chain-Zuständen über kostenlose, öffentliche RPC-Endpunkte (Remote Procedure Call), wie die Standard-URL polygon-rpc.com oder Free-Tiers von Infura, resultiert in katastrophalen Ausführungszeiten. Diese Endpunkte sind massiv Rate-Limitiert und das Routing unterliegt starken Schwankungen.[7] Der Aufbau dedizierter On-Chain-Infrastruktur ist daher obligatorisch.

Eine komparative Analyse der Marktführer für Polygon-Infrastruktur im Jahr 2026 zeigt signifikante Unterschiede in Architektur und Pricing-Modellen:

RPC Provider	Uptime SLA	Pricing-Model (Metrik)	Multiplikatoren / Versteckte Kosten	Primärer Anwendungsfall
Chainstack	99,99 % formal [43]	Request Units (RU)	Keine (1:1 Ratio). 1 RU = 1 Request [44]	Vorhersehbare Kosten, dedizierte Knoten.[45]
QuickNode	99,99 % formal [43]	API Credits	20x bis 120x Multiplikator pro komplexer Methode [44]	Extreme Performance für High-Throughp

				ut dApps.[45]
Alchemy	99,99 % Peak [43]	Compute Units (CU)	10x bis 60x Multiplikator [44]	Teams mit Fokus auf Entwickler-Tools im EVM-Umfeld.[45]
dRPC	K. A. (Routing) [43]	Standard Requests	Gering	Kostenoptimierte Workloads, Multi-Provider-Routing.[45]
Komparative Analyse von Polygon RPC Providern (Stand 2026). [43]				

Für HFT-Bots generiert die Multiplikatoren-Struktur von Anbietern wie QuickNode oder Alchemy enorme Kosten, da eine einzige komplexe Abfrage eines Smart Contracts (wie das Lesen der Gnosis Safe Zustände) als 120 Requests abgerechnet werden kann.[44] Chainstack wird von Systemen, die Skalierung bei Kostensicherheit benötigen, aufgrund des 1:1 Request-Unit-Modells (z. B. 199 USD/Monat für 80 Mio. RU) präferiert.[44]

Das Blockchain Distribution Network (BDN) von bloXroute

Für den ultimativen Latenzvorteil bei der Entdeckung von Mempool-Transaktionen und dem Senden eigener Transaktionen greifen institutionelle Akteure auf spezialisierte Infrastruktur wie das Blockchain Distribution Network (BDN) von bloXroute zurück.[47] bloXroute operiert globale Relay-Netzwerke (Layer 0), die direkte, hochgeschwindigkeits-Netzwerkverbindungen zu einer großen Anzahl von Polygon-Validatoren und Block-Buildern aufrechterhalten.[48]

Benchmark-Tests zwischen bloXroute und Konkurrenten wie BlockRazor belegen die Dominanz: Bei Messungen von Frankfurt aus wurden 42,49 % aller Polygon-Transaktionen auf bloXroute über 10 Millisekunden früher gesehen als beim Konkurrenten.[49] Ein HFT-Bot empfängt über dedizierte WebSocket-Streams (NewTx und PendingTx) von bloXroute Trigger-Signale sofort, wenn sie im P2P-Netzwerk auftauchen.[47] Um die eigene Transaktions-Inklusionsrate (Landing Rate) zu maximieren, implementieren Bots eine Multi-Endpoint-Strategie: Transaktionen werden simultan an die Cloud-API von bloXroute, an ein lokal gehostetes bloXroute-Gateway sowie an konventionelle RPC-Endpunkte gesendet.[50]

Gas-Gebühren-Strategie nach EIP-1559

Das Management der Netzwerkgebühren auf Polygon entscheidet über die Profitabilität. Mit der Einführung des "London Hard Fork" (EIP-1559) wandelte sich das Transaktionsmodell auf Polygon von einer einfachen Erstpreisauktion zu einem zweigeteilten System (Type 2 Transactions).[51]

Anstatt nur einen gasPrice zu bieten, definieren Bots nun zwei Parameter: maxFeePerGas (das absolute Maximum, das der Bot zu zahlen bereit ist) und maxPriorityFeePerGas (der "Tip" oder die Prioritätsgebühr für den Miner/Validator).[51] Das Netzwerk berechnet algorithmisch eine baseFee, basierend auf der Auslastung des vorherigen Blocks, welche verbrannt wird, um das Token-Angebot zu reduzieren.[51]

Die Formel für die endgültigen Transaktionskosten lautet:

$$TotalFee = GasUsed \times (\text{BaseFee} + \min(\text{MaxPriorityFeePerGas}, \text{MaxFeePerGas} - \text{BaseFee}))$$

In Momenten hoher Marktvolatilität, wenn ein Oracle-Delay eintritt und Dutzende Bots simultan versuchen, dieselbe Position auf On-Chain-Level zu liquidieren oder zu mergen, entbrennt eine "Priority Gas Auction" (PGA).[53] Die Validatoren sortieren die Transaktionen im Mempool strikt absteigend nach der Höhe der priorityFee.[52] Der HFT-Bot berechnet in Echtzeit den Expected Value (EV) des Trades. Solange der EV positiv ist, adjustiert der Algorithmus die priorityFee dynamisch nach oben, um Konkurrenten im Mempool exakt zu überbieten.[53] Dies erfordert extrem gasoptimierte Smart Contracts, die Storage-Writes (die teuersten Operationen in der Ethereum Virtual Machine) auf das absolute Minimum reduzieren.[54]

Block-Reorganisationen und probabilistische Finalität

Ein signifikantes architektonisches Risiko für algorithmische Händler auf Polygon PoS ist die probabilistische Finalität des Netzwerks. Im Gegensatz zu deterministischen Systemen kann es auf Polygon zu Block-Reorganisationen (Reorgs) kommen.[55] Reorgs entstehen durch Netzwerklatenzen oder P2P-Verzögerungen, wenn das Netzwerk vorübergehend in zwei Forks (Abzweigungen) gespalten ist.[56] Das Protokoll wählt schließlich die längste/schwerste Kette als kanonisch aus, wodurch die Blöcke der verworfenen Kette "gedroppt" werden.[56]

Historisch wies Polygon PoS eine hohe Frequenz an Reorgs auf; Daten dokumentierten innerhalb von 121 Tagen über 650 Reorgs, wovon ein Drittel eine Tiefe im zweistelligen Bereich aufwies.[55] In extremen Ausnahmefällen kam es zu Reorgs mit einer Tiefe von bis zu 157 Blöcken.[57] Für einen Trading-Bot ist ein Reorg katastrophal: Eine Transaktion, die den Kauf von Polymarket-Anteilen bestätigte, wird aus der Blockchain radiert und fällt zurück in den Mempool. Hat der Bot basierend auf der vermeintlichen Ausführung bereits Hedging-Positionen auf einer anderen Börse (z. B. Binance) eröffnet, führt der Reorg zu massiver ungesicherter Risikoexposition (Unhedged Exposure).

Obwohl Polygon durch Architektur-Upgrades (wie finalitätsfähige Konsensmechanismen,

inspiriert vom AggLayer) die Finalitätszeit drastisch verbessert [58], müssen Bots defensiv programmiert sein. Zentralisierte Börsen wie Kraken forderten zeitweise bis zu 450 "Soft-Confirmations" auf Polygon, bevor Einzahlungen gutgeschrieben wurden.[57] Da HFT-Systeme nicht Minuten warten können, überwachen sie fortlaufend die "Drop"-Werte in den Bor-Logs (den Knotenprotokollen) von Polygon, um das aktuelle Reorg-Risiko des Netzwerks in Echtzeit statistisch zu bewerten und die Positionsgrößen entsprechend anzupassen.[56]

Schutz vor Maximal Extractable Value (MEV)

Der transparente Charakter des öffentlichen Mempools macht ungeschützte Bots zum Ziel von "Predatory Trading". "Searcher" (spezialisierte MEV-Bots) überwachen den Mempool auf profitable Transaktionsaufrufe. Erkennt ein Searcher den lukrativen Trade eines Polymarket-Bots, kopiert er die Transaktionslogik (Calldata), sendet sie mit einer signifikant höheren priorityFee an die Validatoren und sichert sich den Profit durch Front-Running oder verschlechtert den Ausführungspreis durch einen Sandwich-Angriff.[53] Nutzer leiden unbewusst unter erhöhter Slippage oder verpassten Handelsfenstern.[60]

Professionelle Akteure wie Sharky6999 mitigieren dieses existenzielle Risiko, indem sie MEV-Hiding-Strategien anwenden.[60] Sie übermitteln ihre Transaktionen nicht an den öffentlichen P2P-Mempool, sondern routen sie über private, geschützte Endpunkte direkt an Block-Builder.[61] Lösungen wie Flashbots Protect oder spezialisierte MEV-geschützte RPCs (wie dRPC) bieten entscheidende Vorteile [61]:

1. **Unsichtbarkeit:** Die Transaktionsdaten sind vor Konkurrenten verborgen, bis der Block final in die Blockchain geschrieben wird.[60]
2. **Schutz vor Revert-Kosten:** Wenn die Transaktion fehlschlägt (z. B. weil die Liquidität bereits abgeschöpft wurde), wird sie gar nicht erst in den Block aufgenommen. Der Nutzer zahlt keine verschwendeten Gasgebühren für "Reverts".[61]
3. **MEV-Refunds:** Generiert die Transaktion durch ihre Ausführung selbst MEV, können Händler sogar Rückerstattungen auf ihre priorisierten Gasgebühren erhalten.[61]

Im Kontext der bloXroute-Infrastruktur verpacken Händler ihre Transaktionen in private "Bundles". Durch Konfigurationsparameter wie enable_backrunme erlauben sie den Block-Buildern explizit, ihre Transaktion für Arbitragezwecke zu nutzen (Back-running). Im Gegenzug für die Bereitstellung dieser Ertragsmöglichkeit priorisieren die Builder das Bundle des Händlers extrem hoch, was eine nahezu garantierte Inklusion im nächsten Block sichert.[50]

Strategische Synthese

Die eingehende Analyse der On-Chain-Entität "Sharky6999" und der sie umgebenden Infrastruktur dokumentiert eindrucksvoll den Reifegrad und die Industrialisierung dezentraler Prognosemärkte wie Polymarket. Die Realisierung einer historischen Trefferquote von 97 % und

Gewinnen von über einer halben Million US-Dollar belegt empirisch, dass in der Spitze dieses Ökosystems der Erfolg nicht aus fundamentalen Marktprognosen oder Glück resultiert. Er ist das Produkt von deterministischer Latenzarbitrage, bei der Verzögerungen im UMA Optimistic Oracle und Informationsasymmetrien zwischen Off-Chain-Realität und Orderbuch systematisch und in Millisekundenbruchteilen extrahiert werden.

Für die Konzeption, den Aufbau und den Betrieb eines professionellen algorithmischen Handelssystems im Jahr 2026 ist die Beherrschung einer komplexen, mehrschichtigen Architektur zwingend erforderlich. Ein simples Skript zur Abfrage von Web-APIs ist im heutigen HFT-Umfeld obsolet und fungiert lediglich als Liquiditätsspender für überlegene Marktteilnehmer.

Der Aufbau eines kompetitiven Systems erfordert die lückenlose Integration dreier Säulen:

Erstens die **Software-Architektur**, die monolithische Skripte durch hochgradig nebenläufige, in kompilierten Sprachen (wie Go oder Rust) geschriebene Engines ersetzt. Diese müssen Marktdaten exklusiv über WebSocket-Streams konsumieren, komplexe Risiko- und Portfolio-Management-Modelle auf Basis des (fraktionalen) Kelly-Kriteriums berechnen und für ineffiziente Märkte auf KI-Ensembles (Platt-skalierte LLMs wie GPT-4o und Claude 3.5) zur Wahrscheinlichkeitsmodellierung zurückgreifen.

Zweitens die kompromisslose Optimierung der **Netzwerk- und Hardware-Infrastruktur**. Die physikalische Distanz zum Orderbuch-Server (Kolokation in Londoner Rechenzentren) und die Eliminierung von Betriebssystem-Latenzen durch Linux-Kernel-Bypass-Technologien (DPDK) auf compute-optimierten Knoten (wie der AWS z1d-Familie) sind nicht optional, sondern fundamentale Voraussetzungen zur Erreichung von Sub-Millisekunden-Reaktionszeiten.

Drittens die **On-Chain-Exekution**. Das tiefe Verständnis der Polygon-PoS-Spezifika – von der präzisen algorithmischen Navigation von EIP-1559 Priority Gas Auctions über das Abfedern von Block-Reorganisationen bis hin zum rigorosen Schutz vor MEV-Attacken durch private Mempool-Routings – entscheidet final darüber, ob ein theoretischer "Gross Edge" tatsächlich als kapitalisierter "Net Edge" realisiert werden kann.

Akteure, die diese gesamte technologische vertikale Wertschöpfungskette beherrschen, operieren am äußersten Rand der Markteffizienz und sichern sich in einem asymmetrischen Informationskrieg nachhaltige und überdurchschnittliche Renditen.

Referenzen

1. Polymarket | The World's Largest Prediction Market™, Zugriff am April 6, 2026, https://polymarket.com/
2. Polymarket's Use of Polygon and UMA for Decentralized Resolution - MEXC, Zugriff am April 6, 2026, https://www.mexc.com/learn/article/polymarkets-use-of-polygon-and-uma-for-decentralized-resolution/1
3. Polymarket HFT: How Traders Use AI to Identify Arbitrage and Mispricing -

QuantVPS, Zugriff am April 6, 2026, https://www.quantvps.com/blog/polymarket-hft-traders-use-ai-arbitrage-mispricing
4. The Polymarket API: Architecture, Endpoints, and Use Cases | by Jung-Hua Liu | Medium, Zugriff am April 6, 2026, https://medium.com/@gwrx2005/the-polymarket-api-architecture-endpoints-and-use-cases-f1d88fa6c1bf
5. Polymarket: Sharky6999 | Address: 0x751a2b86...159349ea1 ..., Zugriff am April 6, 2026, https://polygonscan.com/address/0x751a2b86cab503496efd325c8344e10159349ea1
6. Polymarket Wallet Achieves 97% Accuracy, Earning $534K in Arbitrage - Phemex, Zugriff am April 6, 2026, https://phemex.com/news/article/polymarket-wallet-achieves-97-accuracy-earning-534k-in-arbitrage-51489
7. Beyond Simple Arbitrage: 4 Polymarket Strategies Bots Actually Profit From in 2026, Zugriff am April 6, 2026, https://medium.com/illumination/beyond-simple-arbitrage-4-polymarket-strategies-bots-actually-profit-from-in-2026-ddacc92c5b4f
8. Trader Nets $50K from Oracle Latency Exploit on Polymarket | Phemex News, Zugriff am April 6, 2026, https://phemex.com/news/article/trader-exploits-oracle-latency-for-50k-profit-in-one-week-45143
9. Polymarket 101, Zugriff am April 6, 2026, https://docs.polymarket.com/polymarket-101
10. Getting Started - Polymarket Documentation, Zugriff am April 6, 2026, https://docs.polymarket.com/market-makers/getting-started
11. How to Setup a Polymarket Bot: Step-by-Step Guide for Beginners - QuantVPS, Zugriff am April 6, 2026, https://www.quantvps.com/blog/setup-polymarket-trading-bot
12. Built a Polymarket trading bot in Go with 8 strategies, WebSocket feed, backtesting built in, Zugriff am April 6, 2026, https://www.reddit.com/r/SideProject/comments/1rq69mj/built_a_polymarket_trading_bot_in_go_with_8/
13. leolopez007/polymarket-trade-tracker: Free tool to analyze Polymarket trades - PnL, Maker/Taker roles, charts & more - GitHub, Zugriff am April 6, 2026, https://github.com/leolopez007/polymarket-trade-tracker
14. Gas estimation - Safe{Wallet} Help Center and Support., Zugriff am April 6, 2026, https://help.safe.global/en/articles/40828-gas-estimation
15. Inside UMA Oracle | How Prediction Markets Resolution Works, Zugriff am April 6, 2026, https://rocknblock.io/blog/how-prediction-markets-resolution-works-uma-optimistic-oracle-polymarket
16. Resolution - Polymarket Documentation, Zugriff am April 6, 2026, https://docs.polymarket.com/concepts/resolution

17. The Ultimate Guide: Building a Polymarket BTC 15-Minute Trading Bot with NautilusTrader, Zugriff am April 6, 2026, https://medium.com/@aulegabriel381/the-ultimate-guide-building-a-polymarket-btc-15-minute-trading-bot-with-nautilustrader-ef04eb5edfcb
18. The Definitive Guide to the Polymarket Ecosystem: 170+ Tools, Bots, and Products Reshaping Prediction Markets - DeFi Prime, Zugriff am April 6, 2026, https://defiprime.com/definitive-guide-to-the-polymarket-ecosystem
19. Overview - Polymarket Documentation, Zugriff am April 6, 2026, https://docs.polymarket.com/trading/orders/overview
20. Create Order - Polymarket Documentation, Zugriff am April 6, 2026, https://docs.polymarket.com/trading/orders/create
21. GitHub - Poly-Tutor/polymarket-arbitrage-trading-bot-tools, Zugriff am April 6, 2026, https://github.com/Poly-Tutor/polymarket-arbitrage-trading-bot-tools
22. Polymarket Changelog, Zugriff am April 6, 2026, https://docs.polymarket.com/changelog
23. Unravelling the Probabilistic Forest: Arbitrage in Prediction Markets - arXiv, Zugriff am April 6, 2026, https://arxiv.org/html/2508.03474v1
24. This Polymarket Strategy Feels Illegal (But Isn't) - YouTube, Zugriff am April 6, 2026, https://www.youtube.com/watch?v=aVYgFM_o_FM
25. I Read the Most Viral Polymarket Bot Threads So You Don't Have To : r/PredictionMarkets, Zugriff am April 6, 2026, https://www.reddit.com/r/PredictionMarkets/comments/1s45zqt/i_read_the_most_viral_polymarket_bot_threads_so/
26. Latency arb - colocation : r/quant - Reddit, Zugriff am April 6, 2026, https://www.reddit.com/r/quant/comments/1rfu1yt/latency_arb_colocation/
27. Polymarket API Now Available in the U.S.: No Longer Geoblocked (2026 Update), Zugriff am April 6, 2026, https://www.quantvps.com/blog/polymarket-us-api-available
28. Rate Limits - Polymarket Documentation, Zugriff am April 6, 2026, https://docs.polymarket.com/api-reference/rate-limits
29. dylanpersonguy/Fully-Autonomous-Polymarket-AI-Trading ... - GitHub, Zugriff am April 6, 2026, https://github.com/dylanpersonguy/Fully-Autonomous-Polymarket-AI-Trading-Bot
30. The most advanced open-source Polymarket trading bot. 7 automated strategies (arbitrage, convergence, market making, momentum, AI forecast), whale tracker with copy-trade simulator, real-time dashboard, parallel market scanner, paper trading mode. 53K+ lines of TypeScript. Contact @DylanForexia on Telegram for custom bots. · GitHub, Zugriff am April 6, 2026, https://github.com/dylanpersonguy/Polymarket-Trading-Bot
31. Polymarket-Trading-Bot-V3/README.md at main - GitHub, Zugriff am April 6, 2026, https://github.com/Novus-Tech-LLC/Polymarket-Trading-Bot-V3/blob/main/README.md
32. Polymarket Copy Trading and Profitable Bot Strategies - YouTube, Zugriff am April

6, 2026, https://www.youtube.com/watch?v=0NLcfJpFvxM
33. Top High-Frequency Trading Server Providers For 2026 - RedSwitches, Zugriff am April 6, 2026, https://www.redswitches.com/blog/top-high-frequency-trading-server-providers/
34. High-Frequency Trading in Crypto: Latency, Infrastructure, and Reality - Medium, Zugriff am April 6, 2026, https://medium.com/@laostjen/high-frequency-trading-in-crypto-latency-infrastructure-and-reality-594e994132fd
35. Faster Polymarket API orders? : r/algotrading - Reddit, Zugriff am April 6, 2026, https://www.reddit.com/r/algotrading/comments/1sbwxbv/faster_polymarket_api_orders/
36. Amazon EC2 instance types by Region, Zugriff am April 6, 2026, https://docs.aws.amazon.com/ec2/latest/instancetypes/ec2-instance-regions.html
37. Amazon EC2 T2 Instances - AWS, Zugriff am April 6, 2026, https://aws.amazon.com/ec2/instance-types/t2/
38. Amazon EC2 Instance Types, Zugriff am April 6, 2026, https://aws.amazon.com/ec2/instance-types/
39. Coinbase: Building an Ultra-Low-Latency Cryptocurrency Exchange on AWS, Zugriff am April 6, 2026, https://aws.amazon.com/video/watch/a413043e5cb/
40. Optimize tick-to-trade latency for digital assets exchanges and trading platforms on AWS, Zugriff am April 6, 2026, https://aws.amazon.com/blogs/web3/optimize-tick-to-trade-latency-for-digital-assets-exchanges-and-trading-platforms-on-aws/
41. Kernel Bypass Techniques in Linux for High-Frequency Trading: A Deep Dive - Medium, Zugriff am April 6, 2026, https://lambdafunc.medium.com/kernel-bypass-techniques-in-linux-for-high-frequency-trading-a-deep-dive-de347ccd5407
42. Kernel Bypass in HFT: How to Reduce Latency in Linux - QuantVPS, Zugriff am April 6, 2026, https://www.quantvps.com/blog/kernel-bypass-in-hft
43. Best Base RPC providers for onchain applications in 2026 - Chainstack, Zugriff am April 6, 2026, https://chainstack.com/base-rpc-providers-2026/
44. Chainstack vs QuickNode vs Alchemy: Which blockchain API is most cost-effective in 2026, Zugriff am April 6, 2026, https://chainstack.com/most-cost-effective-blockchain-api-chainstack-vs-quicknode-vs-alchemy/
45. Best Polygon RPC providers for high-throughput apps in 2026 | Chainstack Blog, Zugriff am April 6, 2026, https://chainstack.com/best-polygon-rpc-providers-2026/
46. QuickNode RPC Provider Overview (2026) | Chainstack Blog, Zugriff am April 6, 2026, https://chainstack.com/quicknode-rpc-provider/
47. Streams and Data - bloXroute, Zugriff am April 6, 2026, https://bloxroute.com/products/streams-and-data/
48. bloXroute: Home, Zugriff am April 6, 2026, https://bloxroute.com/

49. Benchmarking Blockchain Transaction Speeds: bloXroute vs. BlockRazor, Zugriff am April 6, 2026, https://bloxroute.com/pulse/benchmarking-blockchain-transaction-speeds-bloxroute-vs-blockrazor/
50. Algorithmic Trading | bloXroute Documentation, Zugriff am April 6, 2026, https://docs.bloxroute.com/resources/guides/algorithmic-trading
51. EIP-1559: Dynamic Fee Transactions (Type 0x02) Explained | by Andrey Obruchkov, Zugriff am April 6, 2026, https://medium.com/@andrey_obruchkov/eip-1559-dynamic-fee-transactions-type-0x02-explained-849e2036f130
52. EIP-1559 - Polygon Docs, Zugriff am April 6, 2026, https://docs.polygon.technology/pos/concepts/transactions/eip-1559/
53. Riding the Roller Coaster: Gas Fee Spikes Demystified - Polygon, Zugriff am April 6, 2026, https://polygon.technology/blog/riding-the-roller-coaster-gas-fee-spikes-demystified
54. Mastering-Gas-Fees-for-High-Frequency-Trading-Smart-Contracts_-Part - cimaloc, Zugriff am April 6, 2026, https://cimaloc.com/article/Unlocking-Crypto-Mining-Earnings-A-Comprehensive-Guide
55. Polygon's block reorg problem (daily 10+ depth reorgs) : r/0xPolygon - Reddit, Zugriff am April 6, 2026, https://www.reddit.com/r/0xPolygon/comments/10bvruq/polygons_block_reorg_problem_daily_10_depth_reorgs/
56. Reorgs Demystified: Insights From Monitoring With a Sensor Network - Polygon, Zugriff am April 6, 2026, https://polygon.technology/blog/reorgs-demystified-insights-from-monitoring-with-a-sensor-network
57. What number of confirmations is considered secure in Polygon? - Ethereum Stack Exchange, Zugriff am April 6, 2026, https://ethereum.stackexchange.com/questions/162917/what-number-of-confirmations-is-considered-secure-in-polygon
58. Vertical, Integrated, Open: Why Polygon Is Building the Open Money Stack, Zugriff am April 6, 2026, https://polygon.technology/blog/vertical-integrated-open-why-polygon-is-building-the-open-money-stack
59. Polygon Ends Reorgs: Instant Finality on the Blockchain | T E R E S S A on Binance Square, Zugriff am April 6, 2026, https://www.binance.com/en/square/post/30942653598658
60. The Invisible Threat Draining Your Crypto: How CoolWallet Helps You Avoid MEV Traps, Zugriff am April 6, 2026, https://www.coolwallet.io/blogs/blog/mev-protection
61. MEV Protection Overview - Flashbots Docs, Zugriff am April 6, 2026, https://docs.flashbots.net/flashbots-protect/overview
62. MEV Protection 101 & Supported Chains - dRPC, Zugriff am April 6, 2026,

https://drpc.org/blog/mev-protection-nodes/